

CHAPTER TWO

DATA SCIENCE

እንዴት ናችሁ? በላሊው ቻፕተር ውስጥ "Data" በEmerging Technology ውስጥ ምን ያክል አስፈላጊ እንደሆነ አይተናል። ካስታወሳችሁ "Data is regarded as new oil (እንደ ዘይት የሆነ ብንጠቀምበት ብዙ ለውጥ ሊያመጣ የሚችል) and strategic asset (በእቅድ በስትራቴጂ የምንጠቀመው ሃብት (asset))" እንደሆነ አይተን ነበር።

እናም በዚህ ምዕራፍ ደግሞ ስለዚያ ዳታ ነው በስፋት የምናየው። የሚመለከቱትንም በደንብ እያብራራን እንመለከታለን።

✧ Data Science ምንድነው ?

✧ Data and Information ልዩነታቸው ምንድነው ?

✧ Types of Data እነማን ናቸው ?

✧ Big Data ምንድነው ?

Introduction to Data Science

"Data science is an interdisciplinary field that uses scientific methods, processes, algorithms and systems to extract knowledge and insights from noisy, structured and unstructured data."

ይህን አንድ በአንድ እንመልከት

በመጀመሪያ "Data Science is Interdisciplinary field" ነው ስንል ከተለያዩ የትምህርት ዘርፎች ጋር ግንኙነትን ያለው ማለትም የዳታ ሳይንስን እውቀት የምናገኘው ከተለያዩ ፊልዶች (ለምሳሌ፡- Statistics, Computer Science, Mathematics ...) የሚገኙትን ቴክኒኮች (Techniques) እና ቲዎሪዎች (Theories) አንድ ላይ ጨምቀን ነው።

✧ **Data Science** ከተለያዩ ዳታዎች [ለምሳሌ ዳታው Excel File (Unstructured Data) ሊሆን ይችላል፣ ወይ ደግሞ Email (Semi-structured Data)፣ ወይ ደግሞ Audio, Video files (Unstructured Data) ሊሆን ይችላል፤ እናም ከእንደዚህ አይነት ዳታዎች የሚጠቅም እውቀት (knowledge) እና መረጃ (Information) ለማውጣት (Extract ለማድረግ) የምንጠቀምበት የትምህርት ዘርፍ ነው።

✧ ጠቃሚ እውቀቶችን ከላይ ከዘረዘርናቸው ዳታዎች ለማውጣት ግን የተለያዩ ሳይንሳዊ ዘዴዎችን (Scientific methods)፣ የተለያዩ ሂደቶችን (Processes), አንድን ነገር የመስራት ሂደቶች (algorithms) እንዲሁም የተለያዩ ሲስተሞች (Systems) መጠቀም ያስፈልገናል።

Data and Information

 **Data:** is a representation of facts, concepts or instructions in a formalized manner, which should be suitable for communication, interpretation, or processing, by human or electronic machines.

ጽሑፍ "ዳታ" ማለት እውነታዎችን (facts), ፅንሰ-ሀሳቦችን (Concepts) ወይም መርሆዎችን (Instructions) በሰትክክል የተገለፀ ስብስብ ማለት ነው።

እስኪ ምሳሌ እንመልከት።

ስም	ፆታ
1. Abebe	M
2. Chaltu	F
3. Hagos	M

ከላይ ያለው የSection C ተማሪዎች ስም ዝርዝር ከነ ፆታቸው #ዳታ ሊሆን ይችላል።

በሌላ ምሳሌ የSection C ተማሪዎች ID Card ኮድ #ዳታ ተብላን ብንጠየቅ ደግሞ

Name	ID Card Code
1. Abebe	UGR/0001/15
2. Chaltu	UGR/0002/15
3. Beka	UGR/0003/15

መጀመሪያ ስናብራራው "Definition" ኡ ላይ አይታችሁ ከሆነ "In a formalized manner" ይላል አ? በአሁኑ ምሳሌ ላይ ካያችሁት #ኮድ ብቻ ነው ያለው ፆታ ወይ ደግሞ ስልክ ቁጥር የለበትም። የሚሰበሰበው ዳታ እንዲህ ወጥ (ሲነበብ ይጥበቅ ☺) መሆን አለበት እንጂ የተዘበራረቀ መሆን የለበትም። እንደዚህ ማለት ፈልጎ ነው formal ሲል።

 **"Data is unprocessed facts and figures."**

ዳታ አስፈላጊውን ሂደት ያላለፈ ገና #ጥሬ መረጃ ነው። ለምሳሌ Naol ስጦታ ስጦታ, Emerging Course 95/100 ካመጣ Daniel ስጦታ ስጦታ ደግሞ እራሱን ኮርስ 80/100 አመጥቶ ቢሆን፡- ይሄ በራሱ ዳታ ነው። በራሱ ምንም የሚሰጠን ትርጉም የለም ("new oil" ያልነውን እንዳትረሱ) ነገር ግን ወደ ጠቃሚ ነገር (Information) መለወጥ ይችላል። አሁንም እንዴት ነው፡- Naol 95/100 በማምጣቱ A+ አመጣ፤ Daniel ደግሞ 80/100 በማምጣቱ A- አመጣ ቢባል ይሄ ትርጉም ያለው መረጃ ነው።

ጽሑፍ Data is represented with the help of characters such as alphabets (A-Z, ይህ ከላይ በምሳሌ ፆታ ብላን እንደወሰድነው አይነት ነው), digits (0-9, ከላይ ID Card ኮድ ብላን እንደወሰድነው አይነት ነው) or Special

Characters (+, -, /, ×, =,...) ለምሳሌ የተወሰኑ ሰዎች ኮምፒውተር ፓስዎርድ የሚጀምርበት ፊደል ወይም Character ዳታ ቢያስፈልግ የሚከተለውን መሰብሰብ እንችላለን እንደምሳሌ Mercy - @, Jonny- \$, Zack - %)

✧ **Information:** is organized or classified data which has some meaningful values for the receiver.

ይህ ደግሞ ለትርጉም እንዲሁም ቀጥለን የምንፈልገውን ውሳኔ ለመወሰን አመቺ የሆነ መረጃ ነው።

ለምሳሌ አንዱ ተማሪ ግሬድ 3.75/4.00 በማምጣቱ ወደ ቀጣዩ ክፍል #አልፏል ቢባል ሌላው ደግሞ 2.1/4.00 በማምጣቱ #ወድቋል ቢባል ይሄ Information/ መረጃ ነው።

Data Processing Cycle

✧ It is the **re-structuring** or **re-ordering** of data by people or machines to increase their usefulness and add values for particular purpose.

የሚሰጠውን ዳታ እንደገና መስተካከል ያለበትን አስተካከለን፣ መጨመር ያለበትን ጨምረን ወደ ጠቃሚ መረጃ (Information) የምንቀይርበት ሂደት ነው "Data Processing Cycle" የሚባለው። እሱም ሶስት የሚከተሉትን Step'ኦች በውስጡ ይዟል።

Input



Processing



Output

ቀላል ያለ ምሳሌ እንደ 'Input' የሚያገለግለን Raw Data ተማሪዎች ይህን ኮርስ ከመቶ ስንት እንዳመጡ ኮምፒውተር (Excel File) ላይ ፅፈን ከሆነ ይህ Input ነው። ከዚያ CPU Process አድርጎ ስንቶች ከመቶ ከ50 በላይ እንዳመጡ ስንቶች ደግሞ ከ50 በታች እንዳመጡ እንዲያስቀምጥልን የምናረግበት ሂደት "Processing" ይባላል። ከዚያ ከ50 በላይ ያመጡትን አልፈሃል፣ ከዚያ በታች ያመጡትን ደግሞ አላለፍክም ብሎ ከፊት እንዲፅፍልን ካደረግን እሱ "Output" ነው የሚባለው። በኮምፒውተር ቦታ ሰውንም ተክተን ምሳሌውን መመልከት እንችላለን።

Data Types and Its Representation

ይህንን የዳታ አይነት ከሁለት ነገሮች አንፃር ነው የምንመለከተው፡-

✧ ከኮምፒውተር ፕሮግራሚንግ አንፃር

✧ ከራሱ ከዳታው ትንተና አንፃር

Data Types from Computer Programming Perspective

በኮምፒውተር ፕሮግራሚንግ ውስጥ (አብዛኞቻችሁ አሁን ላይ C++ ወይም Python ነው እየተማራችሁ ያላችሁት) እናም በእነዚያ ውስጥ 'Compiler'ኑ ወይም 'Interpreter'ኑ (እነዚህ ያስገባነውን Input ወደምንፈልገው Output የሚቀይሩልን የፕሮግራሚንግ ሲይስተም ናቸው።) እናም አሁን ቀጥላን የምናያቸው የዳታ አይነቶች Programmerኑ የፈለገው Output እንዲመጣለት ወደ Compiler መልዕክት የሚያስተላልፉ ናቸው። ከዚያ Compiler ወይም Interpreter ያደረገውን አድርጎ ውጤቱን ያመጣል 😊።

Common Data Types Include:

✧ **Integers(int)**: is used to store whole numbers.

ይህ የዳታ አይነት ኢንቲጀር (...-3,-2,-1,0,1,2,3...) ለማስቀመጥ ነው የሚጠቅመው።

☞ ለምሳሌ **Python** ☞ (Programming Language) ላይ:- `print(int(8))` ብላችሁ 'Run' ብታደርጉት Output ላይ 8 ነው የሚያመጣለችሁ

:- `print(int(8.7))` ብላችሁም 'Run' ካደረጋችሁት Output ላይ 8 ነው የሚያመጣለችሁ፤ ምክንያቱም እንዳልነው የትኛውንም የሚሰጠውን Input በኢንቲጀር መልክ ስለሆነ የሚይዘው።

✧ **Booleans(bool)** - is used to represent restricted to one of the two values: True or False.

ይህንንም በምሳሌ ስንመለከተው በPython `1<2` ፅፋችሁ 'Run' ብታደርጉት True ነው የሚያመጣለችሁ፤ ወይ ደግሞ `2=3` ብላችሁ 'Run' ብታደርጉት False ነው የሚያመጣለችሁ። በ C++ ም እንደዚህ Boolean Value (True ከሆነ 1 ነው False ከሆነ ደግሞ 0 ነው)።

✧ **Characters(Char)**: is used to store a single character.

ይህ በአንዷ ፊደል/ Character ብቻ የሚሰየም ነው C++ እና Java Programming ቋንቋዎች ላይ በስፋት አለ። ለምሳሌ `Char x = 'b'` አይነት ነገር ካልን `x` እዚህጋር `b`ን ነው የሚወክለው እያልን ነው።

✧ **Floating-point numbers (float)**: is used to store real numbers.

ይህ ደግሞ ከኢንቲጀር በተጨማሪ ዴሲማል ቁጥሮችንም የሚጨምር ነው። ለምሳሌ ከላይም እንዳየነው `print(float(8.7))` ብለን Python ላይ Run ብናደርገው እራሱን 8.7 ነው የሚያመጣልን። `print(float(8))` ካልነው ደግሞ 8.0 ነው የሚያመጣልን፤ በዋናነት ቁጥሮችን በዴሲማል መልክ የሚያስቀምጥ የዳታ አይነት ነው።

✧ **Alphanumeric string (string)**: used to store a combination of characters and numbers.

ይህ ደግሞ ቁጥሮችን እና ፊደላትን (Characters) አንድ ላይ የሚይዝ የዳታ አይነት ነው። ለምሳሌ `"a13"`, `"2015New"...` string የሚባለው ደግሞ በ Quotation (" ") ውስጥ የሚቀመጡ ነገሮች/ ስብስቦች ሁሉ "String" ነው የሚባሉት።

② Data Types from Data Analytics Perspective

በመጀመሪያ **"Data Analytics"** ማለት ምን ማለት ነው ?

ከአንድ ዳታ (raw data) የሚጠቅም መረጃ ለማውጣት እንዲሁም ስለዚያ ዳታ ድምዳሜ ለመስጠት ዳታውን ተንትነን፤ እያንዳንዱ በዳታው ውስጥ ያለውን ነገር አጥንተን የተገኘውን ውጤት ለመፍትሄ የምንጠቀምበት ሂደት ነው "Data Analytics" የሚባለው።

ለምሳሌ የግቢያችሁ ተማሪዎች የመጀመሪያ ሴሚስተር ግሬድ (ውጤት) ዝርዝር ዳታ ቢደርሳችሁ፤ ከተማሩት ግማሹ ተማሪ አላለፈም ከሆነ፡- "ለምንድነው ያላለፉት? ጥራት ያለው ትምህርት ሳያገኙ ቀርተው ነው? በደንብ ሳያነቡ ቀርተው ነው? ያለፉት ተማሪዎችስ ምን አይነት ተማሪዎች ነበሩ? በራሳቸው በደንብ ሰርተው ያለፉ ናቸው?... " በዚህ መልኩ ዳታውን ተንትነን ስናጠና ነው "Data analytics" የሚባለው።

እየገባችሁ ነዋ 

እናም ከData Analytics አንፃር በሶስት ክፍለን እናያችዋለን።

1. Structured Data: is data that adheres (sticks) to a pre-defined data model and is therefore straightforward to analyze.

ይህ የዳታ አይነት Analyze ለማድረግ (ለመተንተን) ብዙም የማይከብድ ወይም ደግሞ ስናየው ራሱ ግልፅ የሆነ ማለት ነው። ለምሳሌ እስኪ ወደ ምግብ ዝግጅት ልውሰዳችሁ  "የሆነ ምግብ የምናዘጋጅበት ዘርዝር መረጃ ያለው ወረቀት (Recipe ) ምግቡን እንድናዘጋጅ ቢሰጠን ሁሉ ነገር እዛ ላይ አለ "ምን ምን እንደሚያስፈልገን (The ingredients), ምግቡን የምንሰራበት ቦታና ጊዜ (Cooking place and time), ቦታው ምን አይነት አየር ሊኖረው እንደሚገባ (Temperature)..." አያችሁ አይደል እንዲህ አይነቱ "Structured Data" ነው።

Common Examples of Structured data are Excel files or SQL Databases.

እስኪ እንደምሳሌ Excel file እንመልከት። Excel file/spreadsheet መቼስ 1st Year ተማሪ ሆኖ የማያውቅ ካለ ጉድ ነው  እናም እዛ ላይ የአንድ ሴክሽን ተማሪዎች ስም ዝርዝር፤ የእያንዳንዱ ኮርስ ውጤት፤ ከዚያ አሸፊ (Average Result)፤ ከዚያ ደረጃቸው (Rank) ካለበት በዚህ መልኩ የተዘጋጀ Excel file (ደግሞ Excelም ብዙ ጊዜ ለእንዲህ አይነት ስራ ነው የሚያስፈልገው በ 'Rows and Columns' አድርገን) እናም በዚህ መልክ ያለውን የዳታ አይነት "Structured Data" ነው የሚባለው።

"SQL Database"ም ከዚሁ ጋር ተቀራራቢ ሆኖ ግን መጀመሪያ፡

 "Database" ምን ማለት ነው ? በተለያዩ አገድም እና ቋሚ መስመሮች የተዘጋጀ ቴብል (A table consisting of rows and columns). እሺ ይህ እንዲህ ከሆነ SQL ደግሞ ምንድነው ? SQL ቋንቋ ነው ማለትም እንደ C++ እና Python  (It is a language of databases) ጥቅሙም በዳታቤዝ (database) ውስጥ ያሉትን ዳታዎች ወይም መረጃዎችን አውጥተን ለመተንተን (Analyze እንድናደርግ) የሚረዳን ነው።

እስኪ ቀለል ያለ ምሳሌ እንመልከት 

Name City Phone no.

1. Henok A.A 0723267

2. Bilise Adama 0756236

3. Melaku Bahirdar 071273

ለምሳሌ ይህ በRow እና Column የተቀመጠ Database ቢሆን በSQL Database language አድርገን ቁጥር አንድ 'Henok' ብናስገባ የእሱን ሙሉ መረጃ (City & phone no.) ማግኘት እንችላለን። ይህ SQL Database ከ Excel file ጋር ትንሽ ተቀራራቢነት አለው፤ ነገር ግን ልዩነት አለው። Excel file program ነው፤ ይህ ግን ቋንቋ (language) ነው። ይህኛው በExcel file ውስጥ ገብቶ Evaluate መደረግ ይችላል፤ እና ሌሎች የተወሰኑ ልዩነቶች አሏቸው።

2. Semi-Structured Data: is a form of structured data that does not conform with the formal structure of data models associated with relational databases, but nonetheless, contains tags or other markers.

ይህ ከላይ ካየነው 'Structured data' ጋር በተወሰነ ደረጃ ተመሳሳይነት ቢኖሩትም ግን ሙሉ አይደለም (ከተሰጠው Relational Database መረጃዎች ጋር Match የሚያረግ (የሚገጣጠም አይደለም)። እንዴት እንደሆነ ላሳያችሁ "Email" ብንወስድ የሆነ መልዕክት ቢላክለን (ማን እንደላከ፣ የላከበት ቀን እና ሰዓት) ማግኘት እንችላለን (ይሄ በከፊል Structured መሆኑን ቢያሳየንም) ነገር ግን ብዙ ኢሜይል ተልኮላችሁ ከሆነ እና እናንተ ማግኘት የፈለጋችሁት ግን የሆነ ኢሜይል ከሆነ የግድ እነዚያን ኢሜይል ወደታች Scroll እያረጋችሁ ወይም ደግሞ ሰርች ማረጋገጥ በታውላለሁ በሆነ ቃል ሰርች ማድረግ አለባችሁ። ስለዚህ "Semi-Structured" የሆነበት አንዱ ምክንያት ይሄ ነው።

✧ Another Examples: JSON (ይህ የJava Script ቋንቋ ነው) and XML (ይህ ደግሞ የHTML Programming ቋንቋ ነው)

✧ It is also known as "self-describing structure."

ማለትም እራሱን በራሱ የሚገልፅ ነው። ለምሳሌ የተላከው ኢሜይል ራሱ ከማን እንደተላከ፣ ሰዓቱን፣ የተላከበት ኢሜይል ያሳያል።

3. Unstructured Data: is information that either doesn't have a predefined data model or is not organized in a pre-defined manner.

ይህ አይነቱ ዳታ ደግሞ **በስርዓት** (Arrange ተደርጎ) ያልተቀመጠ አይነት ዳታ ነው። ለምሳሌ እንደ Audio, Video ያሉትን ነገሮች ብትወስዱ እናንተ እራሳችሁ ናችሁ የእንትና አልበም፣ የእንትና ሙዚቃ ብላችሁ በFolder ምታስቀምጡት።

✧ Common Examples of **unstructured** data include Audio, Video or Image files, Non-SQL Databases, Social Media Posts, Apps, Websites.

✧ **MetaData** - It is data about data.

ይህኛው ሌላኛው ወይም የመጨረሻው ራሱን የቻለ የዳታ አይነት ነው [እላይ ካየነው ስር የሚመደብ አይደለም]። እናም "Metadata" ማለት ስለ አንድ ዳታ የተለያዩ ዳታዎችን የሚሰበስብ ነው። ለምሳሌ በሞጁላችሁም ላይ እንደምትመለከቱት የሆነ "Photograph/ፎቶ በንወስድ" ስለዚያ ፎቶ በስፋት፡- ፎቶው መቼ እንደተነሳ፣ የት እንደተነሳ እና ሌሎች ዳታዎችን ስለፎቶው የሚያጠናው "Metadata" ነው። "Structured data"ን በውስጡ ይዟል።

ኣሁን ደግሞ ስለ "Data Value Chain እና ስለ Big Data" እንዲሁ በስፋት እናያለን።

Data Value Chain

 አንድን ጥሬ ዳታ ሰብስቦ (Data Acquisition)፣ ተንትነን (Data Analysis)፣ ተማኝነቱን እና ጥራቱን አረጋግጦን (Data Curation)፣ ይህን ዳታ ደግሞ አስፈላጊ ቦታ በማስቀመጥ (Data Storage) ጥቅም ላይ የምናውልበት (Data Usage) ሂደት ነው "Data Value Chain  " የሚባለው።

የሚከተሉት ትላልቅ አምስት Step'ኦች እዚህ ስር የሚመደቡ ናቸው።

1 Acquisition: Is the process of gathering, filtering and cleaning data before it is put in a data warehouse or any other storage solution.

ይህ ዳታን የመሰብሰብ፣ የማስተካከል  (የሚጨመር ነገር ካለ መጨመር የሚቀነስም መቀነስ- filtering ) እና ዳታው የማፅዳት  ሂደት ነው። ይህ ደግሞ የሚሆነው ዳታው ለትንተና እንዲሁም ለData warehouse ከመቅረብ በፊት ነው።

"Data Warehouse" ምንድነው ?

የተለያዩ የዳታ ስብስቦች ተስተካክለው (Manage ተደርገው) ለውሳኔ እንዲሁም በቂ መረጃ  ለማግኘት ብቁ ሆነው የሚቀመጡበት የኮምፒውተር ሲደስተም ነው።

✎ "Data Acquisition" ውስጥ እንደተለመደው የምንሰበስበውን ዳታ በወረቀት  ወይ ደግሞ በስልክ  ላይ ፅፈን አይደለም የምናስቀምጠው። ይልቁኑ የሚሰበስብው ዳታ በData Acquisition System'ኦች አማካኝነት ወደ ዲጂታል ፎርም  ተቀይሮ ነው የሚቀመጠው ወይም 'Store' የሚደረገው። ለምሳሌ አንዱ ሲደስተም "Sensor" ነው። ይህን ሴንሰር ተጠቅማችሁ በቤታችሁ ውስጥ ዞር ዞር እያላችሁ ያለውን የTemperature  መጠን ብትመለከቱ፣ መሳሪያው የቴምፕሬቸርን መጠን ለኮምፒውተር ሲደስተም ግብዓት (Input) እንዲመች አድርጎ ነው የሚያስቀምጠው።

2 Data Analysis: Is concerned with making the raw data acquired amenable to use in a decision making as well as domain-specific usage.

ይህ በመጀመሪያው Step (Data Acquisition) ላይ ያገኘነውን ጥሬ ዳታ  ለውሳኔ ተስማሚ  (amenable) እንዲሆን (for decision-making) ወይም ለሌላ ለሆነ ነገር (domain-specific usage) ለመጠቀም አመቺ  እንዲሆን ዳታውን ስንተነትነው "Data Analysis" ይባላል።

✎ Data Analysis involves exploring, transforming and modelling data with the goal of highlighting data, synthesizing and extracting useful hidden information.

ስለዚህ 'Data Analysis' በውስጡ ያካተተው ዳታውን ማሰሰ - በአካፋ  ምናምን  (ስለ ዳታው የተለያዩ ጥናቶችን ማድረግ - Exploring), ጥሬውን ዳታ መቀየር (transformation) እንዲሁም ቅርፅ ማስያዝ (Modelling ) ነው። ይህን ሁሉ የምናደርገው ከጥሬ ዳታው ውስጥ የሚጠቅም መረጃ (Information) ለማውጣት ነው።

3 **Data Curation:** is the active management of data over its life cycle to ensure it meets the necessary data quality requirements for its effective usage.

ይህ Analyse የተደረገው (የተተነተነው) ዳታ ጥራቱን የጠበቀ ግን መሆኑን ማረጋገጥ እና ዳታውን የማደራጀት (Organization) እና አንድ ላይ የማምጣት (Integration) ስራ ነው የሚሰራው።

🌀 Data Curation processes can be categorized into different activities such as content creation (አዲስ ነገር መፍጠር ማለትም ለምሳሌ የራሳችሁ ሺድዮ ሰርታችሁ ዩቲዩብ ፳ ላይ ብትለቁ እሱ "content creation" ይባላል ወይ ደግሞ የራሳችሁ (ከሌላ ቦታ ኮፒ 📄 ያልተደረገ) ፅሁፍም ብትጽኑ እንደዚሁ - ነገር ግን የራሳችሁ ባይሆን እና ከሌላ ቦታ ኮፒ ወይም Forward ያደረጋችሁት ከሆነ - Content curation ነው የሚባለው።), Selection (መጀመሪያ በContent Creation መልክ ከሰራናቸው ዳታዎች ውስጥ ያስፈልጋሉ ያልናቸውን መምረጥ), Classification (በቀላሉ ለማግኘት አመቺ እንዲሆን በመስፈርት ከፋፍሎ ማስቀምጥ), transformation (ይህ ደግሞ ለምሳሌ ዳታው በExcel File 📊 መልክ ኖሮ ከሆነ ወደ Pdf 📄 ስንለውጠው እንደማለት ነው።), Validation (ዳታው ትክክል እና ተገቢ መሆኑን ማረጋገጥ and Preservation (ዳታውን ጥራቱን አስጠብቀን #ማቆየት).

🌀 Data Curation is performed by Expert Curators knowns as Data curators, Scientific curators or Data annotators - hold the responsibility of ensuring that data are trustworthy, discoverable, accessible, reusable and fit their purpose.

4 **Data Storage:** Is the persistence and management of data in a scalable way that satisfies the needs of applications that require fast access to the data.

ዳታውን በቀላሉ ለማግኘት ወይም 'Access ለማድረግ' በሚመች መልኩ አደራጅተን ስናስቀምጠው ነው።

🔑 The four database transaction keys- **ACID**.

በዚህ በ'Data Storage' ስር የምንመለከተው- Database transaction ነው። ይህም ማለት ዳታ 'Store' በሚደረግበት ጊዜ መቀያየር ያለበት የሚቀያይር፣ አንዱ ዳታ በሌላ መተካት የሚኖርበት ከሆነ እና የመሳሰሉ ስራዎችን መስራት ነው። እናም ይዚህን አፈፃፀም የሚመራ አራት መርሆች (guiding principles- ACID) አሉ። የኬሚስትሪው 🧪 አሲድ እንዳይመስላችሁ 😊 ይሄ ሌላ ነው።

🔑 **A- Atomicity:** ይህ በዳታ መሃል የሚፈፀሙት "transactions" ወይ ሙሉ በሙሉ ስኬታማ ይሆናሉ ወይ ደግሞ ሙሉ በሙሉ ይከሸፋሉ። ግማሹ ተቀያይሮ ግማሹ ደግሞ እንዳይቀር የሚያደረገው "Atomicity" ሲይስተም ነው።

🔑 **C- Consistency:** ensures that a transaction can only bring the database from one valid state to another.

ይህ "transaction"ኡ/ ልውውጡ በሚፈፀም ጊዜ የዳታው ትክክለኝነት (correctness) እንደተጠበቀ መሆኑን የሚቆጣጠረው ወይም የሚያረጋግጠው የConsistency ባህሪ ነው።

🔑 **I- Isolation:** ensures that concurrent execution of transactions leaves the database in the same state at the same time.

"transaction"አቺ በተመሳሳይ ሰዓት እና ሁኔታ እየተፈፀሙ መሆናቸውን የሚያረጋግጥ ነው። (ማለትም ተራ በተራ እንዳይፈፀሙ ያንን ነገር የሚያስቀር (Isolate የሚያደርግ) ነው።

🔗 **D-Durability:** guarantees that once a transaction has been committed, it will remain committed.

አንድ ጊዜ የተፈጸመው "transaction" ቶሎ የሚጠፋ ሳይሆን የሚቆይ ነው። እናም ያንን መቆነቱን (durable መሆኑን የሚያረጋግጥ ነው።)

5 **Data Usage:** It covers the data-driven business activities that need access to data.

ይህ የመጨረሻው የተከማቸውን ዳታ አውጥተን በተለያዩ ነገሮች 📄 📱 ተግባራዊ እያደረግን የምንጠቀምበት ደረጃ ነው።

Big Data

🔗 What is Big Data ?

'ትልቅ ዳታ' የሚባል ነገር አለንዱ 🤖 የሚል ጥያቄ ተፈጥሮባችሁ ይሆናል። ነገር ግን 'Big Data' ማለት ብዙ የዳታ ስብስብ ሆኖ እኛ ቀድሞ በምናውቀው መንገድ (በወረቀት ላይ ወይም በአንድ ኮምፒውተር ራሱ ሆኖ በተለመደው መንገድ ኮምፒውተሩ ላይ ጭነን ለመጠቆም ከባድ የሆነ የዳታ አይነት ነው። ይሄ ዳታ የተሰበሰበው ከተለያዩ ምንጮች ነው (ከዚህ በፊት እንዳየነው ከአንድ ምንጭ (Source) ብቻ አይደለም (ለምሳሌ ከExcel file 📄 ብቻ አይደለም) ከተለያዩ Pdfኦች 📄፣ ከተለያዩ ሺድዮች 📧 📁 እና ፎቶዎች፣ Emailኦችም ሊሆኑ ይችላሉ።

ለምሳሌ፡ የማህበራዊ ድህረ ገፅ ዳታ፣ በባንክ ቤት የምንጠቀማቸው ዳታዎች (Transaction processing systems), ትላልቅ የሞባይል አፖች (Mobile Apps),...

🔗 Big Data is:

🔗 **Large Datasets** (ትልቅ የዳታ ስብስብ ነው)

🔗 The category of computing strategies and technologies that are used to handle large datasets.

(እነዚያን ብዙ እና ትላልቅ የዳታ ስብስቦችን አስልተን ለመጠቀም የሚረዱንን ቴክኖሎጂዎች በውስጡ የያዘ ነው።)

🔗 Characteristics of Big Data

🔗 **Big Data** is mainly characterized by 3V:

ከሌሎች የዳታ ስብስቦች (Other data Systems) "Big Data System" በዋናነት በሚከተሉት ነገሮች ይለያል።

1. Volume: refers to the amount of data.

በ"Big Data" ውስጥ የሚገኘው የዳታ መጠን የሚገልፅ ነው።

2. Velocity: refers to the speed of data processing.

በዳታው ውስጥ የሚገኘው መረጃ (information) በምን ያክል ፍጥነት ነው በሲይሶተሙ ውስጥ የሚሄደው።

3. Variety: refers to the number of types of data.

ቅድም እንዳየነው በ"Big Data" ውስጥ የሚገኙ ዳታዎች የተለያዩ አይነት እና ከተለያዩ ምንጮች የተገኙ ናቸው። (ከፎቶ ፣ ከኢሜይል፣ ከተለያዩ ዶኩሜንት  ...)

"Big Data" የሚገለፀበት ዋና ባህሪያቱ እነዚህ ናቸው። በእርግጥ የተወሰኑት ተጨማሪ አሉ።

 **Veracity:** ከእውነት ጋር ያለው ስምምነት ማለት ነው - ማለትም በ'Big Data' ውስጥ የሚገኙት ዳታዎች፡- Accuracy, Quality & Trustworthiness (ታማኝነት) የሚያሳይ ነው።

 **Value:** እያንዳንዱ በ'Big Data' ውስጥ የሚገኘው ዳታ ዋጋ እንዳለው (የሚጠቅሙ መሆናቸውን) የሚያሳይ ነው።

ኮምፒውተሮች (Individual Computers) በ"Big Data" ውስጥ የሚገኙት ዳታዎች መቆጣጠር ስለማይችሉ፣ እነዚህ ውስጥ የሚገኘውን ዳታ ለመቆጣጠር ብዙ ጊዜ የምንጠቀመው "Computer Cluster" የተባለውን ዘዴ ነው።

ምን ማለት ነው ?

"is a set of computers that work together so that they can be viewed as a single system."

Clustered Computing

ቅድም እንዳልነው የተለያዩ ብዙ ኮምፒውተሮች (PCs) በአንድ ኔትዎርክ ተገናኝተው አንድና ተመሳሳይ ስራ ሲሰሩ ነው። 'Cluster' ማለት እራሱ የተለያዩ (ተመሳሳይ) ነገሮች ስብስብ ማለት ነው።

እንዲህ መሆኑ ጥቅሙ ምንድነው ?

 **Resource Pooling:** Combining the available storage space to hold data is a clear benefit.

በCluster ጊዜ በምንጠቀማቸው ኮምፒውተሮች ውስጥ ያለውን የ'Storage' ስፍራ አንድ ላይ በማምጣት ዳታውን እንዲይዝ ማድረግ።

 **High Availability:** provide varying levels of fault tolerance and availability guaranteed.

የተለያዩ የሃርድዌር እና ሶፍትዌር ችግሮች እንዳይፈጠሩ አስቀድሞ ጥንቃቄ የሚያደርግ ነው።

🕒 **Easy Scalability:** Easy to scale horizontally by adding additional machines.

በምንፈልገው አቅጣጫ መጠኑን (Sizeኩን) ማሳደግ እንችላለን።

ማወቅ ያለብን ነገር ደግሞ "**Cluster**" ስንጠቀም:- "Managing Cluster Membership, Coordinating resource sharing and Scheduling Actual work" እነዚህን ስራዎች የሚሰራፈን ሶፍትዌር ያስፈልገናል። ይህንን ደግሞ እንደ "**Hadoop's YARN**" የመሳሰሉ ሶፍትዌሮችን መጠቀም ይቻላል።

Hadoop ምንድነው ?

Hadoop and Its Ecosystem

🔗 Hadoop (Apache-Hadoop) is an open source framework intended to make interaction with big data easier.

'**Hadoop**' (ሃዱፕ) የተባለው ሶፍትዌር ማንም ሊጠቀመው የሚችል (Open Source) ሆኖ ብዙ ትላልቅ ዳታዎችን (large datasets) በቀላሉ ለማስቀመጥ (Store ለማድረግ) እና Process ለማድረግ (በሚያስፈልጋችሁ ጊዜ በቀላሉ ለማግኘት) የሚረዳ ነው። ምናልባት በHadoop ውስጥ Store የሚደረገው የዳታ መጠን (ከጊጋ ባይትስ (gigabytes- 10^9) እስከ ፔታ ባይትስ (petabytes- 10^{15}) የሚደርሱ ሊሆኑ ይችላሉ።

The four key Characteristics of Hadoop

🌱 **Economical:** ወጪ ቆጣቢ ነው- ምክንያቱም የግድ ውድ የሆኑ ኮምፒውተሮች አያስፈልጉንም፤ ተራ የሆኑትን (Ordinary Computers) ሰብስቦ መጠቀም እንችላለን።

🌱 **Reliable:** ታማኝ ነው- ከተለያዩ ምንጮች የሚያገኛቸውን ዳታዎች ኮፒ ወይም ግልባጭ ያስቀምጣል። ያ ብቻም ሳይሆን የሃርድዌር ክፍሉም በጣም ጠንካራ ነው (resistant to hardware failure)

🌱 **Scalable:** "Scalability" የአንድን ነገር መጠን (size) የመጨመር ወይም የመቀነስ ችሎታ ነው። የHadoop Softwareም እንዲሁ ነው ወደ ላይም ወደ ታችም መጠኑን እንደ አስፈላጊነቱ መቀነስ እና መጨመር እንችላለን።

🌱 **Flexible:** የሚያስፈልገንን ያክል ዳታ በውስጡ መጫን እንችላለን። It is flexible and you can store as much structured and unstructured data.

🔗 **Hadoop** በስሩ የሚያጠቃልላቸው ብዙ ነገሮች አሉ (Its Ecosystem)። የ'Big Data'ን ፍላጎት ለሚሟላት ከጊዜ ወደ ጊዜ እያደገ ይገኛል። እስኪ በውስጡ የሚያካታቸውን የተወሰኑ ነገሮች እንመልከት።

- **HDFS:** Hadoop Distributed File System - ይህንን እንደ አንድ የHadoop ሞጁል ውስዳት - holds very large amount of data and provides easier access.
- **YARN:** Yet Another Resource Negotiator - ይህ ከላይ በHDFS ውስጥ የተከማቸውን (Store የተደረገውን ዳታ) ለመቆጣጠር (Manage ለማድረግ) እና ለመሳሰሉ ስራዎች ይረዳናል።

- **Map Reduce:** Programming based data processing - እነዚያን ብዙ ዳታዎች (ጭታ ባይትስ የሚደርሱትን) በትንሽ ከፋፍሎ፣ በቀላሉ ምቹ ለማድረግ የሚረዳ ነው።
- **Spark:** In-memory Data Processing - ይህም እንደ Hadoop ያለ ሶፍትዌር ሲሆን ነገር ግን ከዚያ ይልቅ ፈጣን እና Hadoop በውስጡ ያልያዘውን ነገር ይዟል። ከሃዱፕ ጋር አንድ ላይም ልንጠቀመው ወይም ለብቻውም ልንጠቀመው እንችላለን።

በተጨማሪም ከዚህ በታች የሚገኙትን ከሃዱፕ ጋር ተያያዥ የሆኑ ሶፍትዌሮች ያዟቸው፡-

- **PIG, HIVE:** Query- based processing of data services
- **HBase:** NoSQL Database
- **Zookeeper:** Managing Cluster
- **Oozie:** Job Scheduling

ከዚህም በተጨማሪ የ"Hadoop Ecosystem" ጠቅላላ ተደርጎ ከስራ ድርሻቸው ጋር በአጠቃላይ በአራት ተከፍለው ከስር በፎቶ በምታዩት መልክ ተቀምጧል።

Big Data Life Cycle with Hadoop

1.Ingesting Data into the System: የመጀመሪያው የ"Big Data Processing" ደረጃ ዳታዎችን ወደ ሃዱፕ ሲይስተም (Hadoop System) ማስገባት (Ingest ማድረግ) ነው። ለዚህ ደግሞ በዋናነት ሁለት መሳሪያዎች ያስፈልጉናል።

🔗 **Scoop:** transfers data from RDBMS (relational database - ከሚመለከተው ዳታ ወይም ተያያዥ የሆኑ ዳታዎችን በውስጡ የያዘ) to HDFS (ቅድም ያየነው ሃዱፕ ውስጥ ዳታዎች የሚቀመጡበት ቦታ ነው)

🔗 **Flume:** transfers Event Data (Event data ማለት የአንድ ክስተት ዳታ ማለት ነው፡- ለምሳሌ ቴሌግራም Join (Log in) ያደረጋችሁበት ሰዓት)

2.Processing the Data in Storage

ይህ ሁለተኛው ደረጃ ነው። በHDFS እና በHBase ውስጥ 'Store' የተደረገው ዳታ "Process" የሚደረግበት ወይም ዳታው አንድ ላይ ተሰብስቦ፣ ተደራጅቶ የሚጠቅም መረጃ- information ከውስጡ እንዲወጥ የሚደረግበት ደረጃ ነው።

🔗 Spark and MapReduce Perform Data Processing.

3.Computing and Analyzing Data

ይህ የሶስተኛው ደረጃ ሲሆን የዳታ ትንተና የሚካሄድበት ነው። ለዚህ ደግሞ ሚክተሎችን ሶስት መሳሪያዎች እንጠቀማለን።

🔗 Pig, Hive (ይህ ከቀሩት ሁለቱ የሚሻል ነው) and Impala.

4. Visualizing The Results

ይህ የተተነተነውን እና የተደራጀውን ዳታ ውጤት ተጠቃሚው በቀላሉ እንዲያገኝ ("Access" እንዲያደርግ) የሚደረግበት ነው። ይህን ደግሞ የሚሰሩት የሚከተሉት መሳሪያዎች ናቸው።

 [Hue and Cloudera Search](#)

 የዛሬው ትምህርት እንዲሁም ምዕራፍ ሁለት በዚህ መልኩ ተጠናቋል። አንብቡ! ስንፍና እንዲቆጣጠሩችሁ አትፍቀዱ!

በረቱ! እንወዳችኋለን 

Like and share!! https://t.me/Freshman_tutor_ials